Projet

Le projet consiste à prévoir le nombre de vélos loués à chaque heure dans des bornes libres-services de la ville (système type Vélib'). La variable cible est ici la variable **count**.

Voici un descriptif de l'ensemble des variables :

- *datetime* - date et heure du relevé
- *season* - 1 = printemps , 2 = été, 3 = automne, 4 = hiver
- *holiday* – indique si le jour est un jour de vacances scolaires
- *workingday* - indique si le jour est travaillé (ni week-end ni vacances)
- *weather* - 1: Dégagé à nuageux, 2 : Brouillard, 3 : Légère pluie ou neige, 4 : Fortes averses ou neiges
- *temp* – température en degrés Celsius
- *atemp* – température ressentie en degrés Celsius
- *humidity* – taux d'humidité
- *windspeed* – vitesse du vent
- *casual* - nombre de locations d'usagers non abonnés
- *registered* – nombre de locations d'usagers abonnés
- *count* – nombre total de locations de vélos

L'objectif du projet est de mener à bien la création d'un modèle qui pourrait théoriquement être déployé en production. Les étapes d'exploration des données, de traitement et de preprocessing ne sont bien entendu pas à négliger. Il ne s'agit pas d'une compétition de type *Kaggle*, le projet ne sera pas uniquement noté sur la performance du modèle, mais plutôt sur votre approche complète et la justification de chacun de vos choix.

Comme vu durant le cours, soyez faites attention à certains points :

- quel type de problème dois-je traiter ?
- feature engineering : est-ce que j'utilise les données correctement, toutes les données ?
- data leakage : est-ce qu'une de mes features n'est pas trop explicative ?
- ai-je bien traité toutes les données correctement ?
- est-ce que mon modèle est adapté ?
- etc, etc, etc

Soyez vigilant à expliquer et justifier votre démarche à l'aide de visualisation, de commentaires dans vos codes (pensez aux cellules markdown), etc

In [41]:

```
import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
```

In [42]:

```
df = pd.read_csv("../data/input/velo.csv")
df.head()
```

Out[42]:

	datetime	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count
0	2011-01-01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3	13	16
1	2011-01-01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8	32	40
2	2011-01-01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5	27	32
3	2011-01-01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3	10	13
4	2011-01-01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0	1	1

Analyse de la structure du dataframe

In [43]:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10886 entries, 0 to 10885
Data columns (total 12 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   datetime    10886 non-null  object
 1   season      10886 non-null  int64
```

```
 2   holiday     10886 non-null  int64
 3   workingday  10886 non-null  int64
 4   weather     10886 non-null  int64
 5   temp        10886 non-null  float64
 6   atemp       10886 non-null  float64
 7   humidity    10886 non-null  int64
 8   windspeed   10886 non-null  float64
 9   casual      10886 non-null  int64
 10  registered  10886 non-null  int64
 11  count       10886 non-null  int64
dtypes: float64(3), int64(8), object(1)
memory usage: 1020.7+ KB
```

Analyse descriptive des données

In [44]:

```
df.describe()
```

Out[44]:

	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registe
count	10886.000000	10886.000000	10886.000000	10886.000000	10886.00000	10886.000000	10886.000000	10886.000000	10886.000000	10886.000
mean	2.506614	0.028569	0.680875	1.418427	20.23086	23.655084	61.886460	12.799395	36.021955	155.552
std	1.116174	0.166599	0.466159	0.633839	7.79159	8.474601	19.245033	8.164537	49.960477	151.039
min	1.000000	0.000000	0.000000	1.000000	0.82000	0.760000	0.000000	0.000000	0.000000	0.000
25%	2.000000	0.000000	0.000000	1.000000	13.94000	16.665000	47.000000	7.001500	4.000000	36.000
50%	3.000000	0.000000	1.000000	1.000000	20.50000	24.240000	62.000000	12.998000	17.000000	118.000
75%	4.000000	0.000000	1.000000	2.000000	26.24000	31.060000	77.000000	16.997900	49.000000	222.000
max	4.000000	1.000000	1.000000	4.000000	41.00000	45.455000	100.000000	56.996900	367.000000	886.000

Nombre de valeurs uniques par colonnes

In [45]:

```
df.apply(lambda x: len(x.unique()))
```

Out[45]:

```
datetime      10886
season            4
holiday           2
workingday        2
weather           4
temp             49
atemp            60
humidity         89
windspeed        28
casual          309
registered      731
count           822
dtype: int64
```

Split de la colonne datetime en year, month, day, time afin de pouvoir analyser les variables indépendamment

In [46]:

```
df["datetime"] = pd.to_datetime(df["datetime"])
df['year'] = df["datetime"].dt.year
df['month'] = df["datetime"].dt.month
df['day'] = df["datetime"].dt.day
df['hour'] = df["datetime"].dt.hour
df = df.drop(columns=["datetime"])
```

In [47]:

```
df.describe()
```

Out[47]:

	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registe
count	10886.000000	10886.000000	10886.000000	10886.000000	10886.00000	10886.000000	10886.000000	10886.000000	10886.000000	10886.000
mean	2.506614	0.028569	0.680875	1.418427	20.23086	23.655084	61.886460	12.799395	36.021955	155.552
std	1.116174	0.166599	0.466159	0.633839	7.79159	8.474601	19.245033	8.164537	49.960477	151.039
min	1.000000	0.000000	0.000000	1.000000	0.82000	0.760000	0.000000	0.000000	0.000000	0.000
25%	2.000000	0.000000	0.000000	1.000000	13.94000	16.665000	47.000000	7.001500	4.000000	36.000
50%	3.000000	0.000000	1.000000	1.000000	20.50000	24.240000	62.000000	12.998000	17.000000	118.000
75%	4.000000	0.000000	1.000000	2.000000	26.24000	31.060000	77.000000	16.997900	49.000000	222.000
max	4.000000	1.000000	1.000000	4.000000	41.00000	45.455000	100.000000	56.996900	367.000000	886.000

In [48]:
```
df.head()
```

Out[48]:

	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	casual	registered	count	year	month	day	hour
0	1	0	0	1	9.84	14.395	81	0.0	3	13	16	2011	1	1	0
1	1	0	0	1	9.02	13.635	80	0.0	8	32	40	2011	1	1	1
2	1	0	0	1	9.02	13.635	80	0.0	5	27	32	2011	1	1	2
3	1	0	0	1	9.84	14.395	75	0.0	3	10	13	2011	1	1	3
4	1	0	0	1	9.84	14.395	75	0.0	0	1	1	2011	1	1	4

Les colonnes weather et season sont catégorisées comme numérique / continue alors qu'il s'agit de variable qualitative / discrète

In [49]:
```
df[["weather", "season"]] = df[["weather", "season"]].astype("category")
```

Premières analyses : nous obtenons 6 variables catégorielles, 8 variables numériques et une variable cible numérique

Ajout de quelques graphiques

Analyse de la distribution de la cible afin de repérer la part des outliers

In [50]:
```
sns.displot(df["count"])
```

Out[50]:
```
<seaborn.axisgrid.FacetGrid at 0x2c8052acc10>
```



In [51]:
```
sns.boxplot(x=df["count"])
```

Out[51]:
```
<AxesSubplot:xlabel='count'>
```



Analyse des autres variables

In [52]:
```
fig, ax = plt.subplots(figsize=(20,5))
sns.pointplot(data=df, x='hour', y='count', ax=ax)
ax.set(title='Nombre de vélos loués toutes les heures, on note un pic à 8h et 17h/18h')
```

Out[52]:
```
[Text(0.5, 1.0, 'Nombre de vélos loués toutes les heures, on note un pic à 8h et 17h/18h')]
```



In [53]:

```
fig, ax = plt.subplots(figsize=(20,5))
sns.pointplot(data=df, x='hour', y='count', hue='month', ax=ax)
ax.set(title='Total par heure des vélos loués en fonction des mois, les vélos sont plus loués les mois d été et
```

Out[53]:

```
[Text(0.5, 1.0, 'Total par heure des vélos loués en fonction des mois, les vélos sont plus loués les mois d été
et du début de lautomne')]
```



In [54]:

```
fig, ax = plt.subplots(figsize=(20,5))
sns.pointplot(data=df, x='hour', y='count', hue='weather', ax=ax)
ax.set(title='Nombre de vélos loués en fonction des différents temps les vélos sont plus loués lors des temps f
```

Out[54]:

```
[Text(0.5, 1.0, 'Nombre de vélos loués en fonction des différents temps les vélos sont plus loués lors des temp
s favorables')]
```



In [55]:

```
fig, ax = plt.subplots(figsize=(20,5))
sns.pointplot(data=df, x='hour', y='count', hue='season', ax=ax)
ax.set(title='Nombre de vélos loués en fonction des différentes saisons, les vélos sont moins loués en hiver')
```

Out[55]:

```
[Text(0.5, 1.0, 'Nombre de vélos loués en fonction des différentes saisons, les vélos sont moins loués en hive
r')]
```



In [56]:

```
sns.barplot(data=df, x='season', y='count', ci="sd", palette="dark")
ax.set(title='Nombre de vélos loués en fonction des saisons')
```

Out[56]:

```
[Text(0.5, 1.0, 'Nombre de vélos loués en fonction des saisons')]
```



In [57]:

```
sns.barplot(data=df, x='weather', y='count', ci="sd", palette="dark")
ax.set(title='Nombre de vélos loués en fonction des temps')
```

Out[57]:

```
[Text(0.5, 1.0, 'Nombre de vélos loués en fonction des temps')]
```



Analyse des corrélations afin de voir s'il faudra réduire le nombre de dimension

In [58]:

```
corr = df.corr()

mask = np.triu(np.ones_like(corr, dtype=bool))
f, ax = plt.subplots(figsize=(11, 9))
cmap = sns.diverging_palette(230, 20, as_cmap=True)

sns.heatmap(corr, mask=mask, cmap=cmap, vmax=.3, center=0,
            square=True, linewidths=.5, cbar_kws={"shrink": .5})
```

Out[58]:

```
<AxesSubplot:>
```





Les colonnes atemp / temp sont fortement positivement corrélées et les colonnes workingday / holiday sont fortement négativement corrélées, je décide donc de supprimer les colonnes atemp et holiday. La colonne cible count correspond à la somme des colonnes registered et casual, je décide donc également de ne pas concerver ces colonnes

In [59]:

```
df = df.drop(columns=["atemp", "holiday", "casual", "registered"])
```

Dans le premier graphique, nous observons des outliers, nous allons les supprimer grâce à la médiane et l'écart interquartile

In [60]:

```
print("Shape initiale: {}".format(df.shape))
q1 = df["count"].quantile(0.25)
q3 = df["count"].quantile(0.75)
iqr = q3 - q1
df = df.loc[(df["count"] >=  q1 -(1.5 * iqr) ) & (df["count"] <= q3 +(1.5 * iqr) )]
print("Shape après avoir supprimer les outliers: {}".format(df.shape))
sns.displot(df["count"])
```

```
Shape initiale: (10886, 11)
Shape après avoir supprimer les outliers: (10586, 11)
```

Out[60]:

```
<seaborn.axisgrid.FacetGrid at 0x2c804c3ff10>
```



In [61]:

```
df.describe()
```

Out[61]:

	workingday	temp	humidity	windspeed	count	year	month	day	hour
count	10586.000000	10586.000000	10586.000000	10586.000000	10586.000000	10586.000000	10586.000000	10586.000000	10586.000000
mean	0.676459	20.061494	62.165124	12.776699	175.717079	2011.487814	6.494804	9.977045	11.456641
std	0.467849	7.781496	19.231315	8.173430	156.360023	0.499875	3.464977	5.475961	6.960409
min	0.000000	0.820000	0.000000	0.000000	1.000000	2011.000000	1.000000	1.000000	0.000000

25%	0.000000	13.940000	47.000000	7.001500	40.000000	2011.000000	3.000000	5.000000	5.000000
50%	1.000000	20.500000	62.000000	12.998000	138.000000	2011.000000	6.000000	10.000000	11.000000
75%	1.000000	26.240000	78.000000	16.997900	270.000000	2012.000000	10.000000	15.000000	18.000000
max	1.000000	41.000000	100.000000	56.996900	647.000000	2012.000000	12.000000	19.000000	23.000000

Préparation du dataset pour mettre en place les algorithmes

In [62]:

```
from prettytable import PrettyTable
import xgboost as xgb

# Sklearn metrics for regression models
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

# Sklearn regression models
from sklearn.ensemble import RandomForestRegressor
from sklearn.ensemble import GradientBoostingRegressor

from sklearn.tree import DecisionTreeRegressor

from sklearn.linear_model import LinearRegression
```

Catégorisation des variables

Les colonnes de type "category" doivent être dummifiées, on utilise le paramètre drop_first=True car il est induit que si les x-1 colonnes sont à 0 alors la dernière est à 1. Cela réduit le nombre de colonnes.

Les variables weather et season sont catégorisées commme numériques : l'encodage est purement numérique, cela correspond à de la factorisation. Cela peut poser problème car l'algorithme assumera que deux valeurs proches sont plus similaires que deux valeurs éloignées, ce qui n'est pas forcément le cas. C'est pourquoi les variables sont dummifiées.

Les variables year, month, day et hour n'ont pas été encodées car elles sont de nature cycliques et elles ont beaucoup de valeurs différentes. Les dummifier augmenterait considérablement le nombre de variables. C'est pourquoi la conversion des valeurs en sin/cos est pertinente. En effet, de cette manière, l'algorithme considèrera les heures 0 et 23 comme étant proches.

In [63]:

```
import math

def transformation(column):
    max_value = column.max()
    sin_values = [math.sin((2*math.pi*x)/max_value) for x in list(column)]
    cos_values = [math.cos((2*math.pi*x)/max_value) for x in list(column)]
    return sin_values, cos_values
```

In [64]:

```
df["day_sin"] = transformation(df["day"])[0]
df["month_sin"] = transformation(df["month"])[0]
df["hour_sin"] = transformation(df["hour"])[0]
df["day_cos"] = transformation(df["day"])[1]
df["month_cos"] = transformation(df["month"])[1]
df["hour_cos"] = transformation(df["hour"])[1]
```

Préparation d'un dictionnaire afin de pouvoir remplacer à posteriori les valeurs cos par les heures et pouvoir visualiser graphiquement le nombre de vélos prédit par heure

In [65]:

```
hour = list(df["hour"])
hour_cos = list(df["hour_cos"])
hour_dict = dict(zip(hour_cos, hour))
hour_dict
```

Out[65]:

```
{1.0: 23,
 0.9629172873477994: 1,
 0.8544194045464886: 21,
 0.6825531432186541: 20,
 0.4600650377311522: 4,
 0.20345601305263375: 5,
 -0.06824241336467088: 6,
 -0.33487961217098616: 7,
 -0.5766803221148671: 8,
 -0.7757112907044197: 9,
 -0.917211301505453: 10,
 -0.9906859460363306: 11,
 -0.9906859460363308: 12,
 -0.9172113015054529: 13,
 -0.7757112907044198: 14,
 -0.5766803221148672: 15,
 -0.3348796121709864: 16,
```

```
-0.06824241336467046: 17,
0.2034560130526333: 18,
0.4600650377311516: 19,
0.962917287347799: 22}
```

In [66]:

```
df = df.drop(columns=["day", "month", "hour"])
df
```

Out[66]:

	season	workingday	weather	temp	humidity	windspeed	count	year	day_sin	month_sin	hour_sin	day_cos	month_cos
0	1	0	1	9.84	81	0.0000	16	2011	3.246995e-01	5.000000e-01	0.000000e+00	0.945817	0.866025
1	1	0	1	9.02	80	0.0000	40	2011	3.246995e-01	5.000000e-01	2.697968e-01	0.945817	0.866025
2	1	0	1	9.02	80	0.0000	32	2011	3.246995e-01	5.000000e-01	5.195840e-01	0.945817	0.866025
3	1	0	1	9.84	75	0.0000	13	2011	3.246995e-01	5.000000e-01	7.308360e-01	0.945817	0.866025
4	1	0	1	9.84	75	0.0000	1	2011	3.246995e-01	5.000000e-01	8.878852e-01	0.945817	0.866025
...	...	...	...	...	...	...	...	...	...	...	...	...	...
10881	4	1	1	15.58	50	26.0027	336	2012	-2.449294e-16	-2.449294e-16	-8.878852e-01	1.000000	1.000000
10882	4	1	1	14.76	57	15.0013	241	2012	-2.449294e-16	-2.449294e-16	-7.308360e-01	1.000000	1.000000
10883	4	1	1	13.94	61	15.0013	168	2012	-2.449294e-16	-2.449294e-16	-5.195840e-01	1.000000	1.000000
10884	4	1	1	13.94	61	6.0032	129	2012	-2.449294e-16	-2.449294e-16	-2.697968e-01	1.000000	1.000000
10885	4	1	1	13.12	66	8.9981	88	2012	-2.449294e-16	-2.449294e-16	-2.449294e-16	1.000000	1.000000

10586 rows × 14 columns

In [67]:

```
df_with_dummies= pd.get_dummies(df, columns=["weather", "season"], drop_first=True)
df_with_dummies.head()
```

Out[67]:

	workingday	temp	humidity	windspeed	count	year	day_sin	month_sin	hour_sin	day_cos	month_cos	hour_cos	weather_2	weather_3
0	0	9.84	81	0.0	16	2011	0.324699	0.5	0.000000	0.945817	0.866025	1.000000	0	0
1	0	9.02	80	0.0	40	2011	0.324699	0.5	0.269797	0.945817	0.866025	0.962917	0	0
2	0	9.02	80	0.0	32	2011	0.324699	0.5	0.519584	0.945817	0.866025	0.854419	0	0
3	0	9.84	75	0.0	13	2011	0.324699	0.5	0.730836	0.945817	0.866025	0.682553	0	0
4	0	9.84	75	0.0	1	2011	0.324699	0.5	0.887885	0.945817	0.866025	0.460065	0	0

Analyse des valeurs nulles, il n'y aucune valeur nulle dans le jeu de données, aucune imputation n'est nécessaire

In [68]:

```
df_with_dummies.isna().sum()
```

Out[68]:

```
workingday    0
temp          0
humidity      0
windspeed     0
count         0
year          0
day_sin       0
month_sin     0
hour_sin      0
day_cos       0
month_cos     0
hour_cos      0
weather_2     0
weather_3     0
weather_4     0
season_2      0
season_3      0
season_4      0
dtype: int64
```

Séparation du dataframe en train et test

In [69]:
```
y = df_with_dummies["count"]
x = df_with_dummies.drop(columns=["count"])
```

In [70]:
```
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x ,y, test_size = 0.20, random_state = 2)
```

Comparaison de plusieurs algorithmes et choix des modèles

Le dataset a les charactérisques suivantes :

- La variable cible est quantitative : je ne vais tester que des modèles de régression
- Le jeu de données n'est pas très lourd
- Seules quelques features sont importantes comme nous avons pu le voir dans la matrice de corrélation, beaucoup sont corrélées

In [71]:
```
table = PrettyTable()
table.field_names = ["Model", "Mean Squared Error", "R² score"]

models = [
    LinearRegression(),
    DecisionTreeRegressor(random_state=0),
    GradientBoostingRegressor(random_state=0),
    xgb.XGBRegressor(verbosity=0),
    RandomForestRegressor(random_state=0, n_estimators=300)
]

for model in models:
    model.fit(x_train, y_train)
    y_pred = model.predict(x_test)

    mse = mean_squared_error(y_test, y_pred)
    r2 = r2_score(y_test, y_pred)

    table.add_row([type(model).__name__, format(mse, '.2f'), format(r2, '.2f')])
```

In [72]:
```
table
```

Out[72]:

Model	Mean Squared Error	R^2 score
LinearRegression	11818.89	0.52
DecisionTreeRegressor	3582.65	0.86
GradientBoostingRegressor	4157.84	0.83
XGBRegressor	1529.82	0.94
RandomForestRegressor	1935.95	0.92

Random Forest

Comme nous le voyons dans le tableau ci-dessus, le score R^2, qui évalue la performance du modèle est le plus élevé des modèles choisis, 89% de la variance de la variable count s'explique par les features. L'erreur quadratique moyenne est aussi la plus faible, cela correspond à la différence entre la prédiction et le réel.

In [73]:
```
from sklearn.model_selection import GridSearchCV
```

Fine tune our model

In [74]:
```
param_grid = [
    {"n_estimators": [10, 100, 300], "max_features": [10, 15, 17]},
    {"bootstrap":[False], "n_estimators": [100, 300, 500], "max_features": [5, 10, 15]}
    ]


model = RandomForestRegressor()

grid_search = GridSearchCV(model, param_grid, cv=5, scoring='neg_mean_squared_error')
grid_search.fit(x_train, y_train)
```

Out[74]:
```
GridSearchCV(cv=5, estimator=RandomForestRegressor(),
             param_grid=[{'max_features': [10, 15, 17],
                          'n_estimators': [10, 100, 300]},
                         {'bootstrap': [False], 'max_features': [5, 10, 15],
                          'n_estimators': [100, 300, 500]}],
             scoring='neg_mean_squared_error')
```

In [75]:
```
grid_search.best_params_
```

Out[75]:
```
{'bootstrap': False, 'max_features': 10, 'n_estimators': 500}
```

In [76]:
```
table = PrettyTable()
table.field_names = ["Model", "Dataset", "MSE", 'RMSE', "R² score", "MAE"]
features = list(x.columns)

model = RandomForestRegressor(bootstrap=False, max_features=10, n_estimators=500).fit(x_train, y_train)

def evaluate(x, y, dataset):
    y_pred = model.predict(x)

    mse = mean_squared_error(y, y_pred)
    score = model.score(x, y)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y, y_pred)

    table.add_row([type(model).__name__, dataset, format(mse, '.2f'), format(rmse, '.2f'), format(score, '.2f')

evaluate(x_train, y_train, 'training')
evaluate(x_test, y_test, 'validation')

table
```

Out[76]:

Model	Dataset	MSE	RMSE	R^2 score	MAE
RandomForestRegressor	training	0.00	0.00	1.00	0.00
RandomForestRegressor	validation	1787.22	42.28	0.93	27.78

Nous voyons que le modèle overfit, c'est le risque lorsqu'on utilise des modèles de random forest. Il n'est pas assez général, et "colle" trop aux données d'entrainement.

In [77]:
```
importances = model.feature_importances_
std = np.std([tree.feature_importances_ for tree in model.estimators_], axis=0)
indices = np.argsort(importances)[::-1]

print("Feature ranking:")

for f in range(x_test.shape[1]):
    print("%d. feature %s (%f)" % (f + 1, features[indices[f]], importances[indices[f]]))

plt.figure(figsize=(35,5))
plt.title("Feature importances")
plt.bar(range(x_test.shape[1]), importances[indices], color="cornflowerblue", yerr=std[indices], align="center"
plt.xticks(range(x_test.shape[1]), [features[i] for i in indices])
plt.xlim([-1, x_test.shape[1]])
plt.show()
```

```
Feature ranking:
1. feature hour_sin (0.341578)
2. feature hour_cos (0.229951)
3. feature temp (0.122911)
4. feature workingday (0.081563)
5. feature year (0.066297)
6. feature humidity (0.044233)
7. feature month_sin (0.031974)
8. feature weather_3 (0.014390)
9. feature day_sin (0.013917)
10. feature windspeed (0.013516)
```

```
11. feature month_cos (0.012824)
12. feature day_cos (0.010918)
13. feature season_4 (0.008918)
14. feature season_2 (0.002972)
15. feature weather_2 (0.002780)
16. feature season_3 (0.001256)
17. feature weather_4 (0.000003)
```



XGBRegressor

In [78]:

```
param_grid = [
    {"n_estimators": [10, 200, 300], "max_depth": [0, 5, 10], "learning_rate":[0.015, 0.001, 0.02]},
    {"learning_rate":[0.01, 0.02, 0.03], "n_estimators": [200, 300, 500], "max_depth": [2, 4, 6]}
    ]


model_xgb = xgb.XGBRegressor()

grid_search = GridSearchCV(model_xgb, param_grid, cv=5, scoring='neg_mean_squared_error')
grid_search.fit(x_train, y_train)
```

Out[78]:

```
GridSearchCV(cv=5,
             estimator=XGBRegressor(base_score=None, booster=None,
                                    colsample_bylevel=None,
                                    colsample_bynode=None,
                                    colsample_bytree=None,
                                    enable_categorical=False, gamma=None,
                                    gpu_id=None, importance_type=None,
                                    interaction_constraints=None,
                                    learning_rate=None, max_delta_step=None,
                                    max_depth=None, min_child_weight=None,
                                    missing=nan, monotone_constraints=None,
                                    n...
                                    random_state=None, reg_alpha=None,
                                    reg_lambda=None, scale_pos_weight=None,
                                    subsample=None, tree_method=None,
                                    validate_parameters=None, verbosity=None),
             param_grid=[{'learning_rate': [0.015, 0.001, 0.02],
                          'max_depth': [0, 5, 10],
                          'n_estimators': [10, 200, 300]},
                         {'learning_rate': [0.01, 0.02, 0.03],
                          'max_depth': [2, 4, 6],
                          'n_estimators': [200, 300, 500]}],
             scoring='neg_mean_squared_error')
```

In [79]:

```
grid_search.best_params_
```

Out[79]:

```
{'learning_rate': 0.03, 'max_depth': 6, 'n_estimators': 500}
```

In [80]:

```
table = PrettyTable()
table.field_names = ["Model", "Dataset", "MSE", 'RMSE', "R² score", "MAE"]
features = list(x.columns)

model_xgb = xgb.XGBRegressor(verbosity=0, max_depth=6, n_estimators=500, learning_rate=0.03).fit(x_train, y_tra

def evaluate(x, y, dataset):
    y_pred = model_xgb.predict(x)

    mse = mean_squared_error(y, y_pred)
    score = model_xgb.score(x, y)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y, y_pred)

    table.add_row([type(model_xgb).__name__, dataset, format(mse, '.2f'), format(rmse, '.2f'), format(score, '.

evaluate(x_train, y_train, 'training')
evaluate(x_test, y_test, 'validation')

table
```

	Model	Dataset	MSE	RMSE	R^2 score	MAE
Out[80]:	XGBRegressor	training	795.43	28.20	0.97	19.10
	XGBRegressor	validation	1548.69	39.35	0.94	25.31

Le modèle XGBRegressor obtient un très bon score R^2 sur le jeu d'entraînement, il overfit encore un peu les données.

GradientBoostingRegressor

In [81]:
```
gbr_params = {'n_estimators': 500,
          'max_depth': 6,
          'min_samples_split': 5,
          'learning_rate': 0.01}

table = PrettyTable()
table.field_names = ["Model", "Dataset", "MSE", 'RMSE', "R² score", "MAE"]

model_gbr = GradientBoostingRegressor(**gbr_params).fit(x_train, y_train)

def evaluate(x, y, dataset):
    y_pred = model_gbr.predict(x)

    mse = mean_squared_error(y, y_pred)
    score = model_gbr.score(x, y)
    rmse = np.sqrt(mse)
    mae = mean_absolute_error(y, y_pred)

    table.add_row([type(model_gbr).__name__, dataset, format(mse, '.2f'), format(rmse, '.2f'), format(score, '.

evaluate(x_train, y_train, 'training')
evaluate(x_test, y_test, 'validation')

table
```

	Model	Dataset	MSE	RMSE	R^2 score	MAE
Out[81]:	GradientBoostingRegressor	training	1382.72	37.19	0.94	25.61
	GradientBoostingRegressor	validation	2014.46	44.88	0.92	29.81

Avec ce modèle, les résultats sur les données d'entraînement et de test sont assez similaires, cela signifie que le modèle est plus général, même si le score du modèle est légèrement moins élevé, il est plus général. Le model DecisionTree a également été testé car les résultats étaient meilleurs, mais il overfittait vraiment les données. Le model RandomForestRegressor overfit également trop les données.

Le modèle que je décide de garder est celui ci.

Conclusion

Dans le premier modèle, les variables heures, jours et températures sont celles ayant le plus d'importance dans le modèle, plus de 75% du modèle est expliqué par ces trois variables. On cherche à prédire le nombre de vélos à allouer par heure. Comme on a pu l'observer dans les graphiques, on observe des pics le matin et en fin de journée.

In [82]:
```
y_test = np.array(y_test.values.tolist())
```

In [83]:
```
x_test["hour_cos"] = x_test["hour_cos"].replace(hour_dict)
```

In [84]:
```
fig, ax = plt.subplots(figsize=(30,8))
sns.pointplot(x=x_test["hour_cos"], y=y_test, ax=ax, color='red')
sns.pointplot(x=x_test["hour_cos"], y=y_pred, ax=ax)
ax.set(title='Nombre de vélos loués toutes les heures, on note un pic à 8h et 18h, en bleu la prédiction')
```

Out[84]:
```
[Text(0.5, 1.0, 'Nombre de vélos loués toutes les heures, on note un pic à 8h et 18h, en bleu la prédiction')]
```

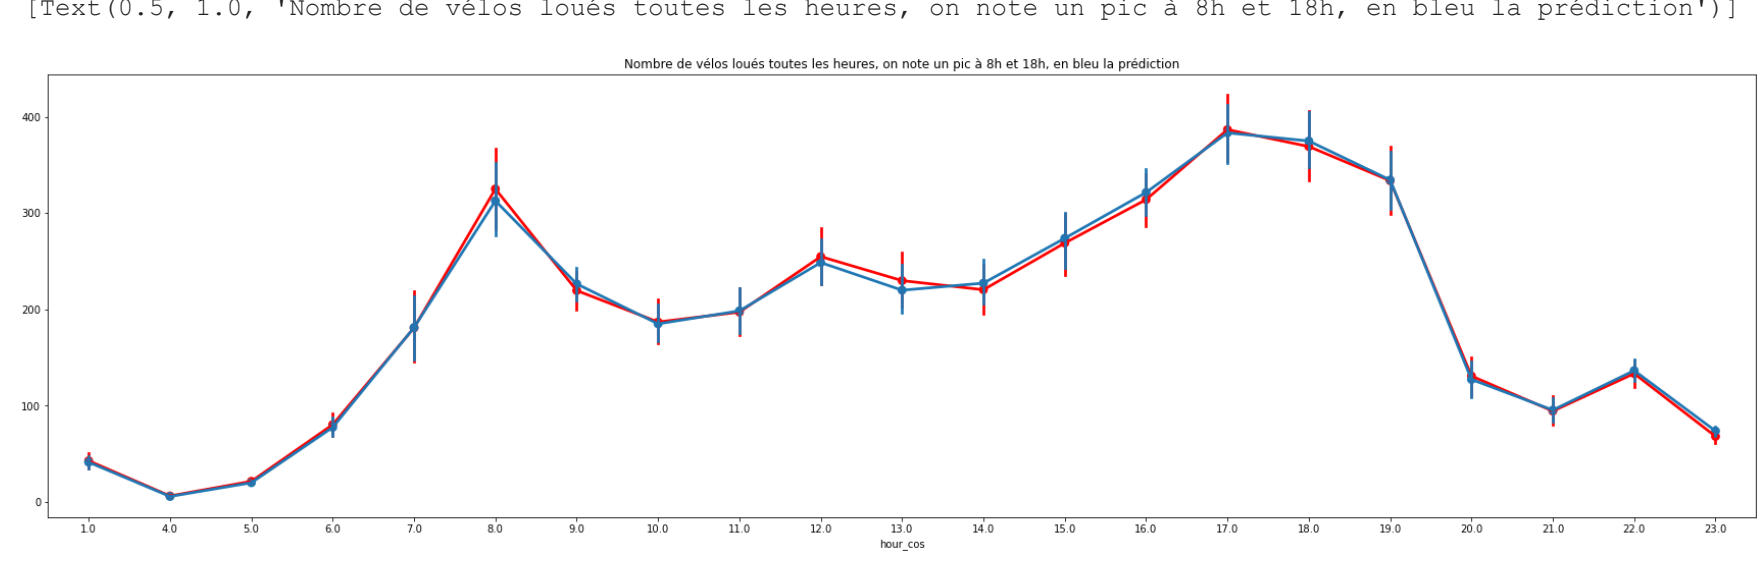

In [85]:
```
jupyter-nbconvert --to PDFviaHTML GAYRAUD_EVA.ipynb
```

```
  File "C:\Users\evaga\AppData\Local\Temp/ipykernel_5568/479933117.py", line 1
    jupyter-nbconvert --to PDFviaHTML GAYRAUD_EVA.ipynb
                           ^
SyntaxError: invalid syntax
```

In [ ]: